Detección automática de Oil Slicks mediante imágenes SAR

Una aplicación a la Región del Golfo de San Matías en Río Negro, Argentina

L. Bailez[1,a], G. Bordenave Vazquez[4,b], D. Bustos[1,c]
U. Cañellas[1,d], F. Leonardis Ayala[1,e], M. Lista[1,f]
L. Martinelli[1,g], A. Porto[3,h], M. Rolando[1,i]
P. Scollo[2,j]

[1]Universidad de Buenos Aires

[2]Universidad Nacional de Mar del Plata

[3]Universidad Nacional del Centro de la Provincia de Buenos Aires

[4]Universidad Nacional de San Martín

[a]bailezleila@gmail.com [b]bordenavezquezgalo@gmail.com [c]daniel.bustos3141@gmail.com
[d]canellasu@gmail.com [e]leonardis.federico@gmail.com [f]melaalista@gmail.com
[g]martinelli.lorenzo12@gmail.com [h]ayrporto@gmail.com [i]mathiasrolando@gmail.com
[j]scollopilar46@gmail.com

Marzo 2026

Resumen

En el marco del Taller de Matemática Industrial (TAMI 2026), en colaboración con la empresa YPF, se abordó la detección automática de manchas de hidrocarburos (oil slicks) en imágenes de Radar de Apertura Sintética (SAR) del satélite Sentinel-1. Se construyó un pipeline de trabajo que va desde la correcta obtención y procesamiento de imágenes hasta la extracción de features y entrenamiento de modelos para la detección de estos oil slicks. A partir de estas se extrajo un vector características geométricas y texturales (como área, perímetro y entropía) para entrenar y comparar modelos de clasificación, específicamente redes neuronales (MLP) y algoritmos k-NN. Los modelos fueron validados mediante métricas de precisión y exhaustividad (recall), y se aplicaron sobre datos reales de la región del Golfo de San Matías, Río Negro, para detectar zonas candidatas (hotspots preliminares) que requieren validación posterior debido a la presencia de falsos positivos.

Palabras clave: Detección de oil slicks, imágenes SAR, Sentinel-1, Filtros Binarios, Feature Extraction, Río Negro.

1. Introducción y Motivación

La detección de hidrocarburos en ambientes marinos es un problema de gran relevancia tanto desde el punto de vista ambiental como en el contexto de la exploración energética.

En este marco, la teledetección mediante sensores de radar de apertura sintética (SAR, *Synthetic Aperture Radar*) se ha consolidado como una herramienta fundamental para el monitoreo de la superficie oceánica.

Entre los fenómenos que pueden detectarse mediante estas imágenes satelitales tenemos a los *oil slicks*, películas de hidrocarburos que se extienden sobre la superficie del mar. Estas pueden originarse tanto por derrames accidentales como por emanaciones naturales de hidrocarburos provenientes del subsuelo marino. Como consecuencia, la rugosidad superficial disminuye. Su efecto puede notarse como manchas oscuras resaltando del mar circundante y pueden medir hasta cientos o miles de metros [1].

Los *slicks* naturales tienen una importancia particular dado que pueden ser indicadores de migración de hidrocarburos desde reservorios profundos hacia la superficie, lo que da indicios de un sistema petrolero activo.

El presente trabajo se centra en el análisis de imágenes SAR con el objetivo de detectar posibles *oil slicks* en el Golfo de San Matías, ubicado en la costa atlántica de la Patagonia argentina.

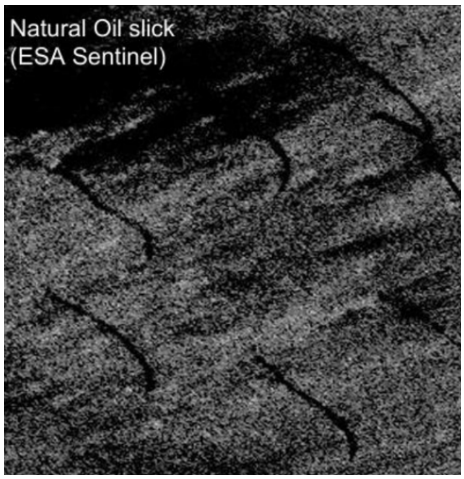

(a) Ejemplos de *oil slicks* en imágenes Sentinel-1.

(b) Ubicación del Golfo de San Matías en la costa atlántica de la Patagonia argentina.

2. Preliminares

Se utilizaron imágenes radar adquiridas en la zona del Golfo San Matías a lo largo del año 2024 por el satélite Sentinel-1. El Radar de Apertura Sintética (SAR), a bordo del satélite Sentinel-1A de la Agencia Espacial Europea (ESA), proporciona imágenes continuas tanto de día como de noche y en prácticamente cualquier condición meteorológica. Las imágenes utilizadas en este trabajo presentan una resolución espacial de 10 m por píxel.

Para la obtención y manejo de las imágenes se utilizó la API de Google Earth Engine, que permite acceder y procesar grandes colecciones de datos satelitales. La localización de las escenas y la identificación de las órbitas del satélite sobre la región de estudio se realizó mediante Copernicus Browser [3]. Los filtros y algoritmos descriptos fueron implementados en Python 3. El código fuente utilizado para el pipeline y los experimentos se encuentra disponible en el repositorio del proyecto [9].

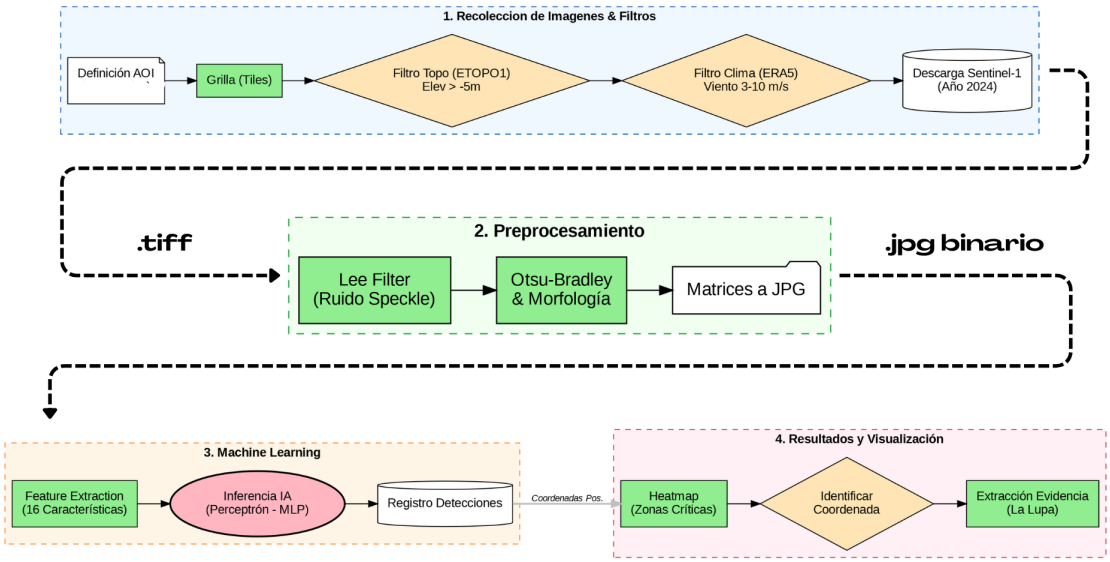

Figura 2: Pipeline completo del sistema de detección de *oil slicks* en imágenes SAR.

3. Metodología

Para abordar la detección automatizada, se diseñó e implementó un flujo de trabajo modular y secuencial. Este pipeline (véase la Figura 2) abarca desde la adquisición y filtrado inteligente de datos satelitales, pasando por el preprocesamiento de la imagen por medio de filtros y la inferencia mediante modelos de clasificación, hasta culminar en la visualización geoespacial de los resultados con un mapa de calor interactivo. A continuación, se detalla cada una de las cuatro etapas que componen la arquitectura del sistema.

3.1. Recolección de imágenes

La selección del Área de Interés (AOI) se centró en la región del Golfo San Matías. En particular, para un primer acercamiento pues la zona es muy vasta para ser procesada en los tiempos disponibles, se decidió utilizar la parte que abarca Playa Bonita y la desembocadura del Río Negro. Se tomó esta decisión, pues el equipo de YPF nos brindó información de que tenían indicios de oil slicks en esa zona. Para procesar esto, el área fue dividida en una grilla de cuadrantes (*tiles*) de 400×400 píxeles, con una resolución espacial de 10 metros por píxel, para que sea coherente con el dataset de entrenamiento que teníamos para nuestro modelo de clasificación.

La detección mediante SAR es altamente sensible a las condiciones ambientales. Para maximizar la fiabilidad y reducir el volumen de procesamiento innecesario, la ingesta de imágenes del satélite **Sentinel-1** (banda C, polarización VV) se condicionó al cruce de datos con dos fuentes satelitales auxiliares:

- **Filtro Topográfico (Modelo ETOPO1):** Se excluyeron todos los cuadrantes con una elevación superior a los -5 metros. Esto garantiza que el análisis se restrinja estrictamente a aguas abiertas, eliminando la interferencia y los falsos positivos generados por la topografía costera o tierra firme.

- **Filtro Climático (ERA5):** La retrodispersión del radar depende de la rugosidad capilar del mar, generada por el viento. Se filtraron las capturas para conservar únicamente aquellas donde la velocidad del viento oscilaba entre 3 y 10 m/s. Vientos inferiores a 3 m/s generan un efecto espejo (falsos positivos), mientras que vientos superiores a 10 m/s dispersan el petróleo [1].

Se limitó la recolección de imágenes al año 2024 por cuestiones de disponibilidad. Además en ese mismo año, se recolectaron muestras de agua de la costa, que luego de su análisis abrieron hipótesis de presencia de oil slicks en la zona.

3.2. Preprocesamiento y realce de manchas oscuras

Las imágenes SAR crudas (formato `.tiff`) presentan un ruido multiplicativo conocido como *Speckle*, el cual degrada la segmentación de los objetos. Para mitigar este efecto, se aplicó un *filtro de Lee*, el cual utiliza estadísticas locales para suavizar áreas homogéneas preservando la nitidez de los bordes estructurales de las manchas.

El preprocesamiento de cada imagen SAR se continuó con una estrategia mixta de umbralado global y local, basada en el enfoque reportado en [6]. El objetivo es conservar la forma general de las manchas oscuras candidatas a ser *oil slicks*.

Dada una imagen en escala de grises I, aplicamos dos filtros por separado: Bradley y Otsu. Luego, usamos una regla de decisión para combinar ambos resultados, en lugar de conservar solo uno.

3.2.1. Detalle del filtro de Otsu

El umbral de Otsu se calcula a partir del histograma de grises de la imagen, normalizado como una distribución de probabilidad $P(i)$. Para cada umbral candidato $T \in \{1, \ldots, 255\}$, se divide el histograma en dos clases $C_1 = [0, T]$ y $C_2 = [T + 1, 255]$, y se evalúa la varianza entre clases:

$$\sigma_B^2(T) = w_1(\mu_1 - \mu_T)^2 + w_2(\mu_2 - \mu_T)^2, \tag{1}$$

donde w_1, w_2 son las probabilidades acumuladas de cada clase, μ_1, μ_2 son sus medias y μ_T es la media global. El umbral final es el que maximiza esta cantidad:

$$T^* = \arg\max_T \ \sigma_B^2(T). \tag{2}$$

En términos prácticos, este procedimiento separa automáticamente regiones oscuras y claras sin fijar un umbral manual, lo que lo hace robusto para distintos contrastes entre mar de fondo y posibles manchas oscuras.

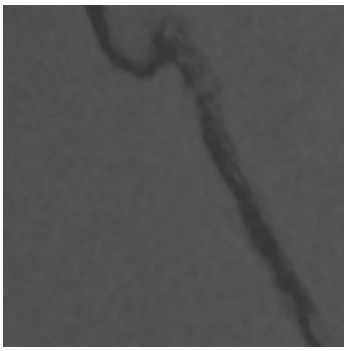

(a) Imagen SAR original.

(b) Resultado tras aplicar Otsu.

Figura 3: Comparación visual del filtrado por umbral de Otsu (antes y después).

Otsu busca maximizar el contraste, independientemente de dónde se encuentren en la imagen. Esto es beneficioso a la hora de identificar manchas petrolíferas con formas irregulares.

3.2.2. Detalle del filtro de Bradley

Nuestro filtro alternativo es el filtro de Bradley. La idea es simple: para cada píxel, se calcula el promedio de intensidad en una ventana cuadrada alrededor suyo y se usa ese promedio como umbral local.

En la implementación, la ventana es de 3x3 y el promedio local de la misma se calcula eficientemente con la imagen integral. Luego, el umbral local se fija como

$$\text{threshold local} = \text{mean local} \cdot \frac{100 - \alpha}{100}, \tag{3}$$

De acuerdo con [6], se eligió $\alpha = 23$. El píxel se binariza como negro si $I <$ threshold local y blanco en caso contrario.

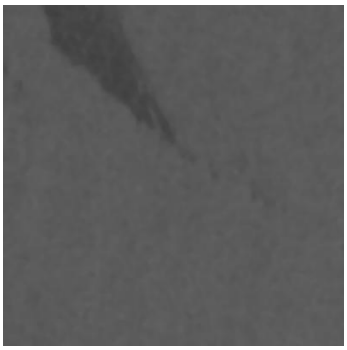

(a) Imagen antes de aplicar Bradley.

(b) Imagen binaria luego de Bradley.

Figura 4: Comparación visual del filtrado Bradley (antes y después).

A diferencia de Otsu, el filtro de Bradley incorpora información local del entorno de cada píxel. Esto ayuda a identificar manchas más homogéneas y a descartar regiones oscuras irrelevantes, como ruido de *backscatter* o sombras generadas por olas. Por otro lado, corre el riesgo de descartar partes relevantes de las manchas de petróleo: como se observa en la Figura 4, si alguna parte de la mancha es más clara que su entorno, se binariza como blanco.

3.3. Criterio de coordinación de filtros

Inspirados en [6], aplicamos ambos filtros a cada imagen y combinamos sus salidas de la siguiente manera. Sean O la imagen filtrada por Otsu, B la imagen filtrada por Bradley, M la intensidad promedio de la imagen original y D el umbral global obtenido por Otsu:

$$F = \begin{cases} B, & \text{si } M < D, \\ O \wedge B, & \text{si } M \geq D. \end{cases} \tag{4}$$

donde $\wedge$ denota la operación lógica *AND*.

Es decir, cuando la escena completa es relativamente oscura ($M < D$), se prioriza la máscara local de Bradley; en caso contrario, se toman solo las manchas en común entre Otsu y Bradley mediante una intersección lógica.

Finalmente, sobre F se aplica posprocesamiento morfológico [7] con elementos circulares: una dilatación con tamaño $(2r + 1) \times (2r + 1)$ seguida de una erosión con tamaño $(2r) \times (2r)$, donde r es el radio morfológico (se tomo r = 3). Este paso suaviza contornos, conecta regiones cercanas y elimina artefactos pequeños.

Finalmente, las imágenes binarias son convertidas a formato JPG.

3.4. Extracción de características de imágenes filtradas

A partir de cada imagen extraemos características geométricas, de intensidad, textura y topología. Estas son tomadas de la versión original como de la imagen binaria, según sea conveniente:

- **Área:** cantidad de píxeles de la región detectada.
- **Perímetro:** longitud del contorno de la región.
- **Excentricidad:** mide cuán alargada es la región (0: circular, cercano a 1: muy alargada).
- **Solidez:** razón entre el área de la región y el área de su cápsula convexa.
- **Extensión (*extent*):** fracción del rectángulo envolvente ocupada por la región.
- **Circularidad:** cercanía de la forma a un círculo (basada en área y perímetro).
- **Elongación:** relación entre eje mayor y eje menor; valores altos indican formas alargadas.
- **Convexidad:** medida de cuánto se parece la región a una forma convexa.
- **Intensidad media:** promedio de intensidades dentro de la región.
- **Desvío estándar de intensidad:** dispersión de intensidades dentro de la región.
- **Intensidad mediana:** valor central de intensidad dentro de la región.
- **Coeficiente de variación:** desvío estándar dividido por la media de intensidad.
- **Contraste con el fondo:** diferencia de intensidad entre la región y su entorno.
- **Varianza local:** variabilidad de intensidad en vecindades locales.
- **Entropía:** medida de complejidad/desorden de textura en la región.
- **Número de regiones:** cantidad de manchas detectadas en la imagen.

3.5. Entrenamiento sobre dataset clasificado

Realizamos la extracción de características sobre las imágenes de un dataset compuesto por imagenes SAR en formato JPG etiquetadas ('Oil' vs 'No Oil') y de acceso público [4]. El objetivo fue entrenar y comparar un modelo k-NN (*K-Nearest Neighbors*) y una red neuronal sencilla, para luego clasificar imágenes del Golfo de San Matías.

Utilizando una partición 75/25 para entrenamiento y validación, se obtuvieron los siguientes resultados:

Cuadro 1: Métricas de validación para los modelos con 16 características.

Métrica	**KNN**	**MLP**
Precisión	84.00 %	85.00 %
Recall	64.00 %	75.40 %
F1-Score	73.00 %	80.00 %
Accuracy global	83.80 %	87.20 %

En la producción final, cada imagen preprocesada del dataset se somete a clasificación bajo este modelo MLP. Las capas ocultas de la red procesan el vector de características empleando funciones de activación no lineales **ReLU** (*Rectified Linear Unit*). La capa de salida, compuesta por dos neuronas, emite valores numéricos brutos sin activación. Durante la inferencia, se aplica la función **Softmax** sobre estos, lo cual permite emitir una clasificación binaria acompañada de una **métrica de confianza porcentual** (representando la probabilidad estadística de la clase predicha). Finalmente, el sistema aplica un umbral operativo, registrando las coordenadas de aquellos cuadrantes evaluados positivamente.

3.6. Visualización

El último módulo del *pipeline* transforma las predicciones aisladas en información útil. A partir de las coordenadas registradas en el paso anterior, el sistema genera un mapa de calor espacial y temporal interactivo. Las coordenadas más rojas representan alta probabilidad de *oil slicks*. De no haber confianza de que se encuentre un *oil slick* en una coordenada, el *heatmap* no mostrará color alguno en esa ubicación. Por cada coordenada con evidencia, se puede hacer clic y obtener un resumen reducido de la probabilidad de *oil slick*, cuántas veces se cree que se halló uno y en qué fechas (ver Figura 6).

Finalmente, el sistema cuenta con una funcionalidad de extracción de evidencia. Dada una coordenada de interés, el algoritmo aísla el cuadrante específico y empaqueta un reporte visual que contiene la imagen SAR original, la imagen filtrada y una imagen SAR ampliada de la coordenada correspondiente en cada fecha donde hubo un *hit* (ver Figura 5). Esta herramienta proporciona el sustento necesario para auditar y validar la decisión del modelo.

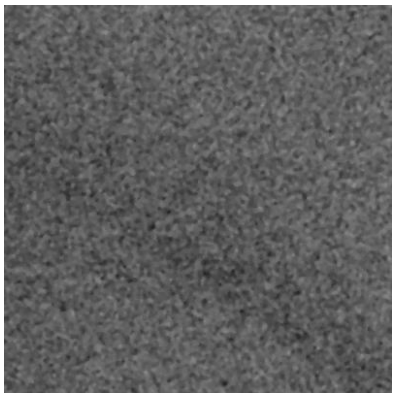

(a) Preprocesamiento.

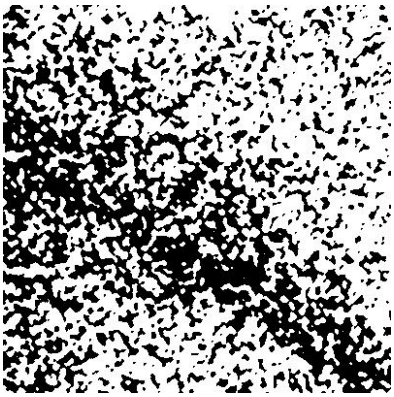

(b) Postprocesamiento.

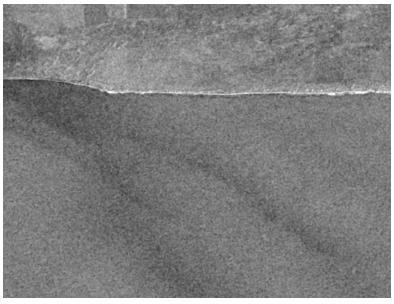

(c) Salida del modelo (ampliada).

Figura 5: Ejemplo para una detección en -41.184, -63.242 el 18-07-2024: imagen preprocesada, resultado postprocesado y salida final del modelo.

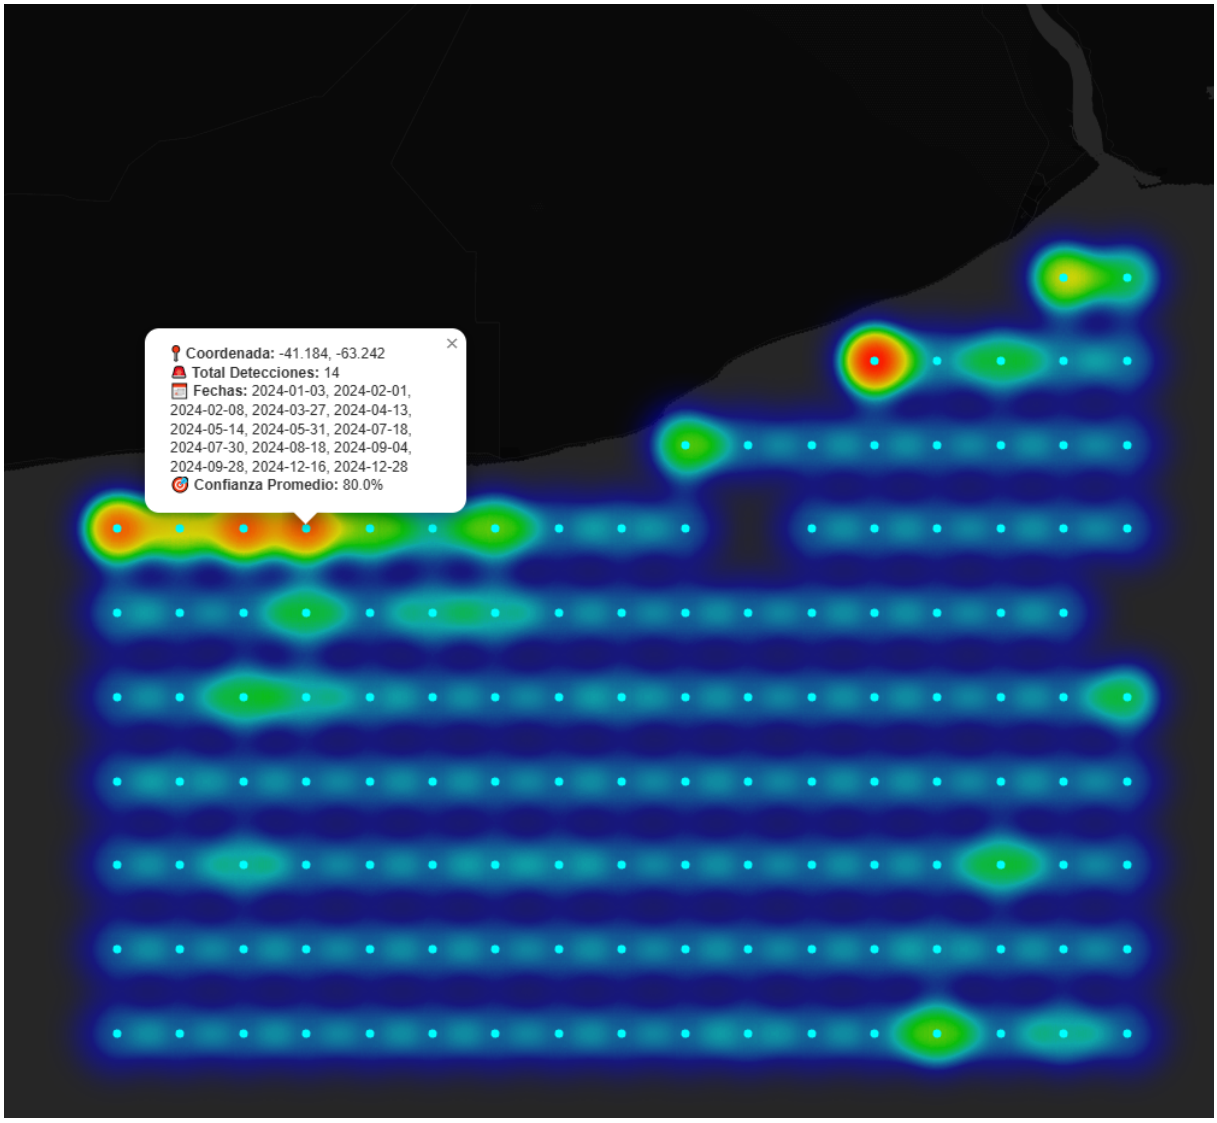

Figura 6: Mapa de calor de detecciones de *oil slicks* en imágenes Sentinel-1 para la región de Playa Bonita. Los puntos con mayor intensidad de color indican mayor probabilidad y frecuencia de detección.

4. Resultados y Análisis

La evaluación del sistema abordó tanto el rendimiento de los algoritmos de clasificación como la aplicación cualitativa de los resultados en la región de Playa Bonita en el Golfo San Matías, Río Negro.

4.1. Rendimiento de los Modelos y Detección Geoespacial

La validación de los modelos confirmó la superioridad del Perceptrón Multicapa (MLP) frente a los enfoques basados en distancias (k-NN). En la partición 75/25 reportada, el modelo MLP obtuvo mejores métricas que k-NN (Tabla 1), por lo que se adoptó para producción. No obstante, estos resultados deben interpretarse como evidencia preliminar hasta incorporar validación cruzada y una cuantificación explícita de la incertidumbre. Las inferencias positivas de este modelo fueron geolocalizadas y mapeadas para construir un *heatmap* temporal del año 2024.

4.2. Análisis de Falsos Positivos y Validación de Campo

El análisis espacial reveló concentraciones de detecciones en coordenadas específicas. Sin embargo, tras la revisión humana de varios de los puntos marcados como de alto interés, se determinó que las anomalías identificadas no pueden ser categóricamente confirmadas como *oil slicks* puros.

Se identificó que una porción significativa de estos falsos positivos se debe a artefactos introducidos durante el recorte de las imágenes SAR. La geometría de la trayectoria orbital del satélite genera recortes accidentados o bordes abruptos en los límites de la franja de captura (*swath*), los cuales alteran la extracción de características geométricas y, consecuentemente, confunden la inferencia de la red neuronal.

A pesar de la presencia de estos falsos positivos inducidos por el recorte orbital, el resultado global del sistema es alentador: el modelo detectó candidatos compatibles con *oil slicks* en zonas de interés preliminar señaladas por el equipo de expertos de YPF. Estas detecciones deben interpretarse como evidencia inicial y no como una confirmación categórica de presencia de hidrocarburos.

5. Trabajo a Futuro

Considerando los resultados obtenidos y la arquitectura desarrollada durante el Taller, se proponen las siguientes líneas de mejora y optimización para la próxima iteración del sistema:

- **Resolución de Recortes Orbitales:** Resulta prioritario pulir la lógica de generación de cuadrantes (*tiles*) para mitigar el problema de los recortes accidentados en los bordes de la trayectoria del satélite, lo que reducirá drásticamente la tasa de falsos positivos geométricos.
- **Expansión del Dataset de Entrenamiento:** Se requiere la adquisición y curaduría de un conjunto de datos de entrenamiento de mayor volumen y variabilidad, lo que permitirá robustecer la generalización de la red neuronal ante distintos estados del mar.

- **Refinamiento de Modelos de Machine Learning:** Debido a las limitaciones temporales del proyecto, el ajuste fino de la red no se agotó. Se propone realizar un refinamiento exhaustivo de los hiperparámetros de los modelos evaluados para maximizar su capacidad discriminativa.
- **Análisis y Selección de Features:** Es necesario llevar a cabo un estudio de correlación profundo entre las 16 características geométricas y texturales extraídas. Una selección de *features* más rigurosa permitirá reducir el ruido multidimensional y optimizar el costo computacional de la inferencia.
- **Escalabilidad y Ampliación de la Zona de Búsqueda:** Dado que el trabajo fue diseñado bajo un enfoque altamente modular, el sistema no está atado a la geografía del Golfo San Matías. Esta modularidad permite adaptar fácilmente el *pipeline* a cualquier región del mundo con cuerpos de agua, habilitando la expansión operativa del monitoreo a otras cuencas de interés.
- **Implementación de una Aplicación Web Integrada:** Como proyección natural de la arquitectura modular desarrollada, se propone migrar el flujo actualmente implementado en notebooks a una aplicación web unificada que facilite la ejecución del pipeline, la visualización de resultados y su uso operativo por parte de usuarios no técnicos.

Referencias

[1] C. Brekke and A. H. S. Solberg, "Oil spill detection by satellite remote sensing," *Remote Sensing of Environment*, vol. 95, no. 1, pp. 1–13, Elsevier, 2005. Disponible en: `https://doi.org/10.1016/j.rse.2004.11.015`

[2] A. H. S. Solberg, "Remote sensing of ocean oil-spill pollution," *Proceedings of the IEEE*, vol. 100, no. 10, pp. 2931–2945, Oct. 2012.

[3] Copernicus Data Space Ecosystem. *Copernicus Browser*. Disponible en: https://browser.dataspace.copernicus.eu/ (último acceso: 13 de marzo de 2026).

[4] H. Krishnacs, *Sentinel-1 SAR Oil Spill Detection Dataset*, Kaggle, 2023. Disponible en: `https://www.kaggle.com/datasets/harikrishnacs/sentinel-1-sar-oil-spill-detection-dataset`

[5] European Space Agency, *Sentinel-1 User Handbook*, ESA, 2013. Disponible en: `https://sentinel.esa.int/documents/247904/685163/Sentinel-1_User_Handbook`

[6] F. Mahdikhani y M. Hassannejad Bibalan, "Detection of oil slicks in SAR satellite images using Otsu-Bradley's thresholding method," *Majlesi Journal of Electrical Engineering (MJEE)*, vol. 19, no. 2, 2025. Disponible en: `https://doi.org/10.57647/j.mjee.2025.1902.24`

[7] OpenCV, "Morphological Transformations," *OpenCV-Python Tutorials*, 4.x. Disponible en: `https://docs.opencv.org/4.x/d9/d61/tutorial_py_morphological_ops.html` (último acceso: 14 de marzo de 2026).

[8] K. Topouzelis, V. Karathanassi, P. Pavlakis y D. Rokos, "Detection and discrimination between oil spills and look-alike phenomena through neural networks," *ISPRS Journal of Photogrammetry and Remote Sensing*, vol. 63, no. 3, pp. 301–312, 2008.

[9] Repositorio del proyecto TAMI 2026 (código fuente). Disponible en: `https://github.com/FedeLeonardis/oil-slick-detection` (último acceso: 24 de marzo de 2026).